# Помощник первокурсника ИВТ МИЭМ НИУ ВШЭ

Поиск информации по программам учебных дисциплин
2026-2027 учебный год




**Над проектом работал:**



**Виктор Бобков**

# Какую задачу решает помощник

«Какие темы входят в дискретную математику?»
«Из чего складывается оценка по программированию?»
«Какие учебники рекомендованы по алгебре?»

Чтобы ответить, студенту нужно найти программу дисциплины и нужный раздел внутри неё.
Помощник выполняет этот поиск: принимает вопрос обычным текстом, находит материал и показывает краткий ответ со ссылкой.
В основе решения — поиск по сохранённым программам дисциплин.

# Как пользоваться помощником

После запуска программы пользователь открывает помощника в браузере. Все дальнейшие действия выполняются на одной странице:

1. Выбрать дисциплину из списка или оставить автоматический поиск.
2. Ввести вопрос обычным текстом.
3. Нажать «Найти ответ».
4. Прочитать ответ и перейти по ссылке на официальную программу.
5. При необходимости раскрыть «Найденный фрагмент», чтобы проверить основание ответа.

Для нового вопроса достаточно изменить текст и снова нажать «Найти ответ».

# Откуда берутся данные

Загрузчик обходит обе страницы каталога ВШЭ и собирает ссылки на программы.
На странице каждой дисциплины проверяются учебный год и наличие первого курса.
Всего собрано 25 программ за 2026–2027 год.

Обычные, углублённые и индустриальные варианты сохраняются отдельно: у них могут различаться темы и правила оценивания.
Для каждой программы сохраняются исходная страница и официальный URL. Поэтому найденные сведения можно проверить.

# Как программы превращаются в базу знаний

Из страниц извлекаются полезные разделы: содержание, оценивание, литература, цели и сведения о дисциплине. Меню и служебные элементы сайта исключаются.
Данные сохраняются по структуре:
Дисциплина → раздел → текст → ссылка на источник.



Длинные разделы делятся на фрагменты примерно по 1000 символов. Соседние фрагменты перекрываются на 120 символов, чтобы уменьшить потерю контекста на границах.
База хранится локально. При каждом вопросе повторно скачивать программы не нужно.

# Как программа разбирает вопрос

Сначала определяется дисциплина.
Если пользователь выбрал её в списке, поиск ограничивается этой программой. Иначе помощник ищет название в вопросе. При нескольких подходящих вариантах предлагает уточнение.

Затем определяется нужный раздел по ключевым словам:
• «формула», «аттестация» → промежуточная аттестация;
• «учебники», «литература» → список литературы;
• «темы», «содержание» → содержание дисциплины.
Это правила, заданные в коде. Они сужают поиск, но могут ошибаться на необычных формулировках.

# Как сравниваются слова

Перед поиском вопрос и фрагменты проходят одинаковую обработку:

- буквы переводятся в нижний регистр;
- текст разбивается на слова;
- частые служебные слова исключаются;
- длинные слова сокращаются до первых семи символов.

Последний шаг помогает частично сгладить различия окончаний. Например, «программирование» и «программирования» получают одинаковое начало.

Это упрощение: оно не заменяет полноценный разбор русского языка и может объединять разные слова.

# Как выбирается лучший фрагмент

Каждое совпавшее со словами вопроса слово добавляет фрагменту баллы.
Вес зависит от распространённости слова среди рассматриваемых фрагментов:
• частое слово получает меньший вес;
• редкое — больший.
Например, «работа» встречается во многих разделах и слабо уточняет поиск. «CMake» встречается реже и точнее указывает на инструменты программирования.

Повторение слова внутри фрагмента тоже учитывается, но его вклад постепенно уменьшается: многократное повторение не увеличивает баллы пропорционально. Баллы складываются, и фрагменты сортируются по сумме. Это лексическое ранжирование с весами редких слов. Оно оценивает совпадения текста, а не понимает смысл вопроса.

# Как формируется ответ

Программа берёт наиболее подходящий фрагмент, выбирает из него пункты или предложения и показывает сокращённую выдержку.
Если дисциплина определена, используется один фрагмент. При поиске по всей базе — до двух. Каждая выдержка ограничена по длине.



Рядом отображаются:
- название дисциплины и раздела;
- ссылка на официальную программу;
- найденный фрагмент, который можно раскрыть.

Такой метод называется экстрактивным резюмированием: ответ извлекается из документа. Внешняя LLM во время работы помощника не вызывается.

# Пример прохождения запроса

Вопрос: «Какая формула оценивания?»
Выбрана дисциплина: «Алгоритмизация и программирование — углублённый курс».

1. Выбор дисциплины ограничивает поиск одной программой.
2. Слово «формула» направляет поиск в промежуточную аттестацию.
3. Из раздела извлекаются условия оценивания.
4. Пользователь получает формулу со ссылкой.

Для второго модуля программа указывает:
35% — лабораторные работы;
20% — контрольная работа;
20% — экзамен;
15% — активность на семинарах;
10% — активность на лекциях.
Помощник находит эту формулу в источнике, но самостоятельно оценку по ней не рассчитывает.
Это правила, заданные в коде. Они сужают поиск, но могут ошибаться на необычных формулировках.

# Почему выбран такой подход

Для первого прототипа важны простой запуск и проверяемость ответа.

- Не требуются API-ключи и платные запросы.
- После скачивания базы можно работать без интернета.
- Ответ сопровождается материалом, из которого он получен.
- На фиксированной базе результаты воспроизводимы.



Компромисс: поиск хорошо подходит для конкретных сведений, но хуже справляется с перефразировками, объяснениями и сравнением документов.

# Как проверялось решение

Подготовлены 30 вопросов с фактическими ответами и источниками.
20 базовых вопросов проверяют четыре сценария по пяти дисциплинам: содержание, формулы оценивания, литературу и модули обучения.
Для каждого запроса заранее выбран контрольный факт. Проверка проходит, если этот факт присутствует в ответе и ссылка ведёт на нужную программу.

Результат — 20 из 20 базовых проверок.
Ещё 10 сложных запросов демонстрируют недостатки. Этот набор не включён в показатель успешности. Результаты сохранены в отдельном отчёте.

# Где решение ошибается и что улучшить

Найденный фрагмент не всегда даёт полный ответ:
• синонимы и сокращения могут не распознаться;
• совпадение слов может привести к неподходящему тексту;
• сокращение выдержки может скрыть часть условий;
• сравнение дисциплин и расчёт оценки не реализованы.

За два дополнительных дня:
День 1 — перепроверить базу, выделить формулы в отдельные поля, добавить сокращения, обработку русских слов и семантический поиск.
День 2 — подключить LLM для объяснения найденного материала с источниками, добавить сравнение дисциплин и калькулятор оценок.
Повторить тестирование на новых вопросах: проверять правильность, полноту, ссылки и корректность уточнений при недостатке данных.